

# Crawling

- requests
- BeautifulSoup
  - find / find\_all
  - select\_one / select

## ■ URL

### ● Uniform Resource Locator

①      ②      ③      ④      ⑤      ⑥  
● https://news.naver.com:80/main/read.naver  
⑦  
?mode=LSD&mid=shm&sid1=105&oid=001&aid=0009847211  
⑧  
#da\_727145

① http:// or https:// - Protocol

② news - Sub Domain

③ naver.com - Domain

④ :80 - Port

⑤ /main/ - Path

⑥ read.nhn - Page (Document)

⑦ ?mode=LSD&mid=shm&sid1=105&oid=001&aid=0009847211 - Query String (Parameter)

⑧ #da\_727145 - Fragment

## ■ Crawling

- 조직적 / 자동화 된 방법으로 데이터를 탐색하거나 수집하는 것
- 데이터 수집 절차
  - 원하는 URL에 request를 보내고 결과를 받아온다
  - 받은 결과물 (HTML / JSON / XML)을 파싱(Parsing)한다
  - 필요한 정보만 추출한다
- 파이썬에서 크롤링을 하기 위해 필요한 라이브러리
  - 데이터 통신 : requests / urllib
  - 데이터 추출 : bs4 (BeautifulSoup)

※ selenium

## ■ 웹 페이지의 종류

### ● 정적 페이지

- <http://ggoreb.com/http/get/>




- <http://ggoreb.com/http/post/>



### ● 동적 페이지

- <http://ggoreb.com/http/json/>



## ■ requests vs selenium

### ● requests

- 받아오는 문자열에 따라 두가지 방법으로 구분
- html / xml : requests + BeautifulSoup
- json : requests

### ● selenium

- 브라우저를 직접 열어서 데이터를 받는 방법
- 웹 드라이버를 통해 브라우저를 제어

### ※ 속도 순위

requests > requests + BeautifulSoup > selenium

json

html / xml

브라우저 제어

## ■ requests

### ● 모듈 가져오기

```
import requests
```

### ● URL 호출 후 응답코드 확인

```
result = requests.get('http://ggoreb.com/http')  
print(result.status_code)
```

200

### ● 응답결과 확인

```
print(result.text)
```

```
"<html lang='ko'>\n<head>\n    <meta charset='utf-8' >\n</head>\n<body>\n<h3>\n    <a href='#'>í\x97\x88ë\x8b\x88ë¹\x84</a>\n"
```

## ■ requests

### ● Encoding 처리 (한글 깨짐)

#### 1) 인코딩 방식 직접 지정

```
res = requests.get('http://ggoreb.com/http/euc-kr.jsp')
res.encoding = 'euc-kr'
print(res.text) # 한글 테스트 euc-kr
```

#### 2) 응답 헤더의 인코딩 정보 사용

```
res = requests.get('http://ggoreb.com/http/euc-kr.jsp')
print(res.headers['Content-Type']) # text/html; charset=euc-kr
print(res.text) # 한글 테스트 euc-kr
```

#### 3) 응답 헤더를 무시하고 추정된 값 사용

```
res = requests.get('http://ggoreb.com/http/euc-kr.jsp')
print(res.apparent_encoding) # utf_16_le
res.encoding = None
print(res.text) # 깨짐
```

## ■ requests

### ● Parameter 사용 (GET - params)

```
import requests

url = 'http://ggoreb.com/python/api/request_get.jsp'
query_params = {
    'search': '파이썬',
    'page': 1
}

res = requests.get(url, params=query_params)
print(res.text)
```

```
{
  "status": "success",
  "method": "GET",
  "data": {
    "search": "파이썬",
    "page": 1
  }
}
```



## ■ requests

### ● Parameter 사용 (POST - data)

```
import requests

url = 'http://ggoreb.com/python/api/request_post.jsp'
login_data = {
    'uid': 'student01',
    'upw': 'pass1234'
}

res = requests.post(url, data=login_data)
print(res.text)
```

```
{
  "status": "success",
  "message": "로그인 성공! student01님 환영합니다."
}
```

## ■ requests

### ● Header 사용

```
import requests

url = 'http://ggoreb.com/python/api/request_header.jsp'
header_data = {
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) Chrome/120.0.0.0',
    'My-Macro-Key': 'GGOREB_SECRET_1234'
}

res = requests.get(url, headers=header_data)
print(res.text)
```

```
{
  "status": "success",
  "message": "헤더 정보를 성공적으로 확인했습니다.",
  "headers_received": {
    "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) Chrome/120.0.0.0",
    "My-Macro-Key": "GGOREB_SECRET_1234"
  }
}
```

## ■ requests

### ● Parameter + Header 사용 (POST - json)

```
import requests

url = 'http://ggoreb.com/python/api/request_json.jsp'
user_info = {
    'name': '홍길동',
    'skills': ['Python', 'Data', 'AI']
}
req_headers = {
    'Authorization': 'Bearer GGOREB_TOKEN',
    'User-Agent': 'Mozilla/5.0'
}

res = requests.post(url, json=user_info, headers=req_headers)
print(res.text)
```

```
{
  "status": "success",
  "auth": "Verified",
  "received_json": {"name": "\ud64d\uae38\ub3d9", "skills": ["Python", "Data", "AI"]}
}
```

## ■ requests

### ● 요청 메소드 ( GET / POST / PUT / DELETE )

```
import requests
res = requests.get(
    'http://ggoreb.com/http/method.jsp' )
print(res.text)
```

<h1>Method => <span style="color:blue;">GET</span></h1>

```
import requests
res = requests.post(
    'http://ggoreb.com/http/method.jsp' )
print(res.text)
```

<h1>Method => <span style="color:red;">POST</span></h1>

```
import requests
res = requests.put(
    'http://ggoreb.com/http/method.jsp' )
print(res.text)
```

<h1>Method => <span style="color:green;">PUT</span></h1>

```
import requests
res = requests.delete(
    'http://ggoreb.com/http/method.jsp' )
print(res.text)
```

<h1>Method => <span style="color:yellow;">DELETE</span></h1>

## ■ requests

### ● 데이터 추출하기

```
import requests
result = requests.get(
    'http://ggoreb.com/python/html/data1.html').text
s_idx = 0
e_idx = 0
while True:
    s_idx = result.find('<td>', e_idx)
    if s_idx == -1: break
    e_idx = result.find('</td>', s_idx)
    print(result[s_idx + 4 : e_idx])
```

#### Basic HTML Table

| Firstname | Lastname | Age |
|-----------|----------|-----|
| Jill      | Smith    | 50  |
| Eve       | Jackson  | 94  |
| John      | Doe      | 80  |

```
<body>
<h2>Basic HTML Table</h2>
... <table style="width:100%"> == $0
  <tbody>
    <tr>...</tr>
    <tr>
      <td>Jill</td>
      <td>Smith</td>
      <td>50</td>
    </tr>
    <tr>
      <td>Eve</td>
      <td>Jackson</td>
      <td>94</td>
    </tr>
    <tr>
      <td>John</td>
      <td>Doe</td>
      <td>80</td>
    </tr>
  </tbody>
</table>
</body>
```



Jill  
Smith  
50  
Eve  
Jackson  
94  
John  
Doe  
80

## ■ 연습문제

### ● 당첨번호와 보너스 번호 출력하기

```
110 <body>
111   <div class="win_result">
112     <h4><strong>1000회</strong> 당첨결과</h4>
113     <p class="desc">(2022년 01월 29일 추첨)</p>
114     <div class="nums">
115       <div class="num win">
116         <strong>당첨번호</strong>
117         <p>
118           <span class="ball_645 lrg ball1">2</span>
119           <span class="ball_645 lrg ball1">8</span>
120           <span class="ball_645 lrg ball2">19</span>
121           <span class="ball_645 lrg ball3">22</span>
122           <span class="ball_645 lrg ball4">32</span>
123           <span class="ball_645 lrg ball5">42</span>
124         </p>
125       </div>
126       <div class="num bonus">
127         <strong>보너스</strong>
128         <p><span class="ball_645 lrg ball4">39</span></p>
129       </div>
130     </div>
131   </div>
132 </body>
```



```
import requests
address = 'http://ggoreb.com/python/html/number.html'
res = requests.get(address)
```

방법 1) find() + slicing

방법 2) 정규 표현식

2  
8  
19  
22  
32  
42  
39

## ■ 연습문제

### ● 이미지의 경로 출력하기


```
← → ↻ ⓘ 주의 요약 | view-source:ggoreb.com/python/html/attribute.html
1 <!DOCTYPE html>
2 <html>
3 <head>
4 <meta charset="utf-8">
5 <title>Insert title here</title>
6 </head>
7 <body>
8     <div class="info">
9         
10        
11        
12        
13    </div>
14 </body>
15 </html>
```



```
import requests
address = 'http://ggoreb.com/python/html/attribute.html'
res = requests.get(address)
```

## ■ JSON (requests)

### ● JSON 문서 확인



### ● {} dictionary

```
import requests
res = requests.get('http://ggoreb.com/python/json/data1.jsp')
parse = res.json() # JSON → Dictionary
print(type(parse))
print(parse['age'])
print(parse.get('name'))
```

```
<class 'dict'>
```

```
10
```

```
GGoReb
```



## ■ JSON (requests)

### ● JSON 문서 확인

The screenshot shows a web browser window with the address bar displaying `ggoreb.com/python/json/data2.jsp`. The page content displays a JSON array containing three objects. Each object is highlighted with a blue box and labeled as "{} JSON Object". The array itself is highlighted with a purple box and labeled as "[] JSON Array".

```
[  
  {  
    "age": 10,  
    "name": "A"  
  },  
  {  
    "age": 11,  
    "name": "B"  
  },  
  {  
    "age": 12,  
    "name": "C"  
  }  
]
```

Raw Parsed

## ■ JSON (requests)

### ● [] list

```
import requests
res = requests.get('http://ggoreb.com/python/json/data2.jsp')
parse = res.json() # JSON → List
print(type(parse))
for data in parse:
    print(data.get('age'))
    print(data.get('name'))
```

```
<class 'list'>
10
A
11
B
12
C
```

```
[
  {
    "age": 10,
    "name": "A"
  },
  {
    "age": 11,
    "name": "B"
  },
  {
    "age": 12,
    "name": "C"
  }
]
```

## ■ JSON (requests)

### ● dictionary + list

```
url = 'http://ggoreb.com/python/api/request_lotto.jsp'
res = requests.get(url)

print(f"--- res.text 출력 (자료형: {type(res.text)}) ---")
print(res.text)

print(f"\n--- res.json() 변환 후 출력 (자료형: {type(res.json())}) ---")
data = res.json()

print("회차 정보:", data['drwNo'])
print("로또 번호 리스트:", data['lotto_numbers'])
print("3번째 번호는?:", data['lotto_numbers'][2])
```

--- res.text 출력 (자료형: <class 'str'>) ---

```
{
  "drwNo": 1231,
  "drwNoDate": "2026-07-05",
  "lotto_numbers": [4, 13, 14, 18, 31, 38],
  "bonusNo": 15,
  "status": "success"
}
```

--- res.json() 변환 후 출력 (자료형: <class 'dict'>) ---

```
회차 정보: 1231
로또 번호 리스트: [4, 13, 14, 18, 31, 38]
3번째 번호는?: 14
```

```
{
  "drwNo": 1231,
  "drwNoDate": "2026-07-05",
  "lotto_numbers": [
    4,
    13,
    14,
    18,
    31,
    38
  ],
  "bonusNo": 15,
  "status": "success"
}
```

## ■ 연습문제

### ● 쇼핑물 정보 및 상품 현황 출력하기

- 요청 URL: [http://ggoreb.com/python/api/request\\_market.jsp](http://ggoreb.com/python/api/request_market.jsp)

- 요구사항

- 1) 응답 데이터 구조 확인 후 "쇼핑물 이름"과 "전체 상품개수" 출력
- 2) 모든 상품명과 가격 출력
- 3) 출력 형식

[XYZ 쇼핑물 상품 현황 - 총 3개]

- 상품명: 맛있는 제주 한라봉 3kg | 가격: 29900원
- 상품명: 유기농 아보카도 5과 | 가격: 15900원
- 상품명: 프리미엄 견과류 세트 | 가격: 42000원

## ■ 연습문제

### ● 전국 실시간 미세먼지 및 대기질 현황 출력하기

- 요청 URL: [http://ggoreb.com/python/api/request\\_weather.jsp](http://ggoreb.com/python/api/request_weather.jsp)

- 요구사항

1) 전체 지역 중 대기질이 나쁨인 지역만 필터링 후 출력

(state 나쁨 또는 action\_required True)

2) 출력 형식

[전국 대기환경 관측소 - 15:00 기준 위험 지역 안내]

 경보 지역: 인천 중구 | 미세먼지 농도: 85 (상태: 나쁨)

 경보 지역: 경기 수원 | 미세먼지 농도: 78 (상태: 나쁨)

## ■ 연습문제

### ● 실시간 영화 예매 차트 현황 및 평점 계산/출력하기

- 요청 URL: [http://ggoreb.com/python/api/request\\_movie.jsp](http://ggoreb.com/python/api/request_movie.jsp)

- 요구사항

- 1) 각 영화의 순위(rank), 제목(title), 예매율(booking\_rate), 평점(star) 출력
- 2) 모든 영화 평점의 평균 출력
- 3) 출력 형식

[메가박스 종합 차트 현재 순위]

[1위] AI 시대의 서막 | 예매율: 42.5% (평점: 9.2점)

[2위] 파이썬 탈출기 | 예매율: 28.1% (평점: 8.8점)

[3위] 코딩 지옥 | 예매율: 12.4% (평점: 6.5점)

=====

🔥 현재 상영작 평균 평점: 8.17점